

VERİ BİLİMİ FİNAL SINAVI PROJESİ RAPORU

E-Ticaret Veri Analizi ve Müşteri Segmentasyon Projesi

Hazırlayan: İlker Özdemir

Öğrenci Numarası: 1306240061

Teslim Tarihi: 03.07.2026

1. Problem Tanımı

Bu çalışmanın temel amacı, e-ticaret platformuna ait satış verilerini analiz ederek müşteri davranışlarını anlamlandırmak ve RFM (Recency, Frequency, Monetary) analizi ile müşterileri anlamlı segmentlere ayırmaktır. Bu analiz, veri odaklı pazarlama stratejileri geliştirmek, müşteri sadakatini artırmak ve gelir kaybını (churn) minimize etmek için temel oluşturacaktır.

2. Veri Seti ve Kaynağı

Projede, Kaggle üzerinden temin edilen ve e-ticaret platformunda gerçekleşen satış işlemlerini içeren "E-Commerce Data" (Online Retail) veri seti kullanılmaktadır.

2.1. Veri Kaynağı Hakkında

Bu projede kullanılan veri seti, 2010-2011 yılları arasında Birleşik Krallık merkezli bir online perakende şirketinin gerçekleştirdiği tüm işlemleri içeren, uluslararası düzeyde kabul görmüş bir kaynaktır.

* Veri Seti Adı: E-Commerce Data (Online Retail).

* Platform: Kaggle.

* Zaman Aralığı: 01/12/2010 ile 09/12/2011 tarihleri arasındaki bir yıllık süreci kapsamaktadır.

* Veri Niteliği: Transnasyonel (uluslararası) bir niteliğe sahip olması, farklı ülkelerden gelen müşteri davranışlarının karşılaştırmalı analizine (RQ1) olanak tanımaktadır.

* Akademik Önemi: Veri seti, gerçek dünya işlemlerini yansıttığı için temizleme, RFM analizi, zaman serisi modellemesi ve kümeleme gibi veri bilimi disiplinlerinde bir "benchmark" (kıyaslama) seti olarak kabul edilmektedir.

2.2. Veri Hazırlama Süreci

Veri hazırlama aşamasında aşağıdaki işlemler uygulanmıştır:

- * Tip dönüşümleri (Tarih ve zaman verilerinin ayrıştırılması).
- * Gürültülü verilerin temizlenmesi (Negatif değerler ve aykırı uçlar).
- * Eksik verilerin (Missing values) anlamlı şekilde doldurulması işlemleri gerçekleştirilmiştir.

3. Yöntem

Proje süreci, uçtan uca bir veri bilimi metodolojisi izlenerek gerçekleştirilmiştir:

- * Veri Hazırlama: Tarih verilerinin ayrıştırılması, gürültülü verilerin (negatif fiyat/miktar) temizlenmesi ve eksik verilerin doldurulması sağlanmıştır.
- * RFM Metriklerinin Hesaplanması: Müşteri bazında Recency (son alışverişten bu yana geçen gün), Frequency (toplam alışveriş sayısı) ve Monetary (toplam harcama) metrikleri hesaplanmıştır.
- * Ölçeklendirme (Scaling): Kümeleme algoritmalarının hassasiyeti nedeniyle veriler standartlaştırılmıştır (StandardScaler).
- * Kümeleme Algoritması: K-Means algoritması seçilmiş ve optimum küme sayısını belirlemek için "Dirsek (Elbow)" yöntemi kullanılarak atalet (inertia) analizi gerçekleştirilmiştir.

4. Bulgular

4.1. Keşifsel Veri Analizi (EDA) ve Yöntemler

Bu aşamada verinin yapısını anlamak için temel istatistiksel yaklaşımlar ve görselleştirme teknikleri kullanılmıştır.

- * Temel İstatistikler: Merkezi eğilimleri (ortalama, medyan) ve yayılımı incelemek amacıyla betimsel istatistikler kullanılmıştır.
- * Görselleştirme Teknikleri:
 - * Sütun Grafikleri: Kategorik verilerin karşılaştırılmasında kullanılmıştır.
 - * Çizgi Grafikleri: Zaman içindeki mevsimsel trendleri izlemek için kullanılmıştır.
 - * Kutu Grafikleri (Box Plots): Veri dağılımı ve uç değer analizi için kullanılmıştır.
 - * Dirsek (Elbow) Grafiği: Optimum küme sayısını belirlemek için kullanılmıştır.

Analiz Bulguları:

* Ülke Analizi (RQ1):

Birleşik Krallık dışındaki pazarlarda Almanya, Fransa ve EİRE ülkeleri sipariş hacmi bakımından liderdir. Kutu grafiği, en çok sipariş veren ilk 5 ülkenin sepet tutarı medyanlarının birbirine çok yakın olduğunu ortaya koymaktadır; bu durum, ciro farkının sepet büyüklüğünden ziyade işlem sıklığından kaynaklandığını kanıtlamaktadır.

* Müşteri Davranışları (RQ2):

Yıl bazlı trendlerde yıl sonuna (Kasım/Aralık) doğru ciroda belirgin bir artış gözlemlenmiştir. Günlük bazda ise haftanın çalışma günlerinde (özellikle Perşembe) işlem hacminin zirve yaptığı, Cumartesi günleri ise işlemlerin neredeyse durduğu gözlenmiştir.

4.2. RFM ve K-Means Segmentasyonu (RQ3)

Dirsek yöntemi ile yapılan analiz sonucunda optimum küme sayısı k=4 olarak belirlenmiştir. Kümelerin RFM medyan değerleri özetlenmiştir:

CLUSTER	RECENCY	FREQUENCY	MONETARY	MÜŞTERİ SAYISI
0	17.0	2.0	403.65	819
1	177.0	1.0	243.79	1610
2	53.5	4.0	1120.62	1196
3	8.0	10.0	3187.28	713

5. Sınırlamalar

Çalışmanın kapsamı ve elde edilen sonuçlar aşağıdaki kısıtlar dahilinde değerlendirilmelidir:

* Zaman Kısıtı: Analiz belirli bir dönemle sınırlı olduğu için müşteri davranışlarındaki uzun vadeli değişkenlikler (örneğin yıllar arası eğilimler) tam olarak yansıtılamamış olabilir.

* Veri Kalitesi: Eksik verilerin doldurulması süreçlerinde yapılan varsayımlar ve aykırı değerlerin temizlenmesi aşamasındaki eşik değer seçimleri, model çıktılarını kısmen etkileyebilecek teknik tercihlerdir.

* Kapsam: Analiz sadece satın alma verilerine dayalıdır; müşteri demografik özellikleri veya sosyal medya etkileşimleri gibi dışsal veriler modele dahil edilmemiştir.

6. Öğrenilenler

Bu çalışma sürecinde elde edilen temel kazanımlar şunlardır:

* Teknik Uygulama: Ham bir veri setinin temizlenmesi, normalize edilmesi ve anlamlı metrikler (RFM) üretilmesi sürecinde veri ön işlemenin model başarısı üzerindeki kritik etkisi tecrübe edilmiştir.

* Algoritmik Yetkinlik: K-Means kümeleme algoritmasının parametre optimizasyonu (Elbow metodu) ve sonuçların yorumlanması aşamalarında, teorik bilginin pratik iş kararlarına nasıl dönüştürülebileceği gözlemlenmiştir.

* Analitik Bakış Açısı: Sadece kod yazmanın yeterli olmadığı, veri bilimi projelerinde iş sonuçlarına odaklanan (churn önleme, VIP segmentasyonu) bir stratejik yaklaşımın esas değer önerisi olduğu anlaşılmıştır.

Bu çalışma, veri ön işleme, Keşifsel Veri Analizi (EDA) ve makine öğrenmesi süreçlerini içeren uçtan uca bir veri bilimi projesidir.